

**FUNDAÇÃO ESCOLA DE COMÉRCIO ÁLVARES PENTEADO**  
**CAMPUS LIBERDADE**  
**BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO**

Flávia da Costa Rodrigues Faria – 20021548

Guilherme Muniz Gomes – 24026572

Lucas Moreira Godoy – 24026298

Maria Eduarda Cabral Foloni – 24026502

## **PicMoney**

### **1. Introdução**

#### **1.1. Contexto do Projeto**

Dando continuidade à primeira entrega do projeto PicMoney, esta etapa teve como foco a integração, limpeza e exploração aprofundada dos dados, consolidando uma base analítica robusta. O propósito foi desenvolver um pipeline de dados estruturado que permita entendimento detalhado do comportamento dos usuários, sustentando futuras análises preditivas e dashboards de Business Intelligence.

O objetivo central foi integrar as quatro bases disponíveis (cadastros, transações, pedestres e massa de teste), realizar um diagnóstico de qualidade, padronizar formatos e desenvolver variáveis derivadas que permitam análises preditivas e segmentação comportamental dos clientes.

## 1.2. Objetivo Específico

Explorar o comportamento dos usuários, cruzando dados demográficos, transacionais e geográficos, de modo a identificar padrões de uso, oportunidades de retenção e estratégias de expansão da base de clientes.

## 2. Coleta e Carregamento das Bases

As bases foram carregadas diretamente do repositório GitHub do grupo, utilizando `pandas.read_csv()` com delimitador;.

### Bases Utilizadas

Base	Descrição	Volume
<b>Base_Cadastral_de_Players.csv</b>	Informações pessoais e comportamentais dos usuários.	10.000 registros
<b>Base_de_Transacoes_e_Cupons_Capturados.csv</b>	Histórico de compras, cupons e repasses.	100.000 registros
<b>Base_Simulada_de_Pedestres_Av__Paulista.csv</b>	Movimentação e presença de pedestres	100.000 registros

Base	Descrição	Volume
	com/sem app PicMoney.	
<b>Massa_de_Teste_com_Lojas_e_Valores.csv</b>	Dados complementares de lojas e valores simulados.	10.000 registros

### 3. Entendimento e Diagnóstico dos Dados

#### 3.1. Análise Estrutural

Foi utilizada a inspeção inicial (.info(), .describe(), .isnull().sum()) para avaliar tipos, estrutura e consistência.

Principais achados:

Campos nulos em bairro e cidade\_trabalho/escola (~70%).

Campos monetários com formatação inconsistente (vírgula decimal, símbolos R\$).

Colunas de latitude/longitude com separadores duplicados.

Datas válidas e coerentes.

Campo “produto” em transações apresenta muitos valores nulos ( dado opcional).

#### 3.2. Tratamento Inicial

Durante essa etapa, foi identificado que os datasets estavam preparados para integração futura, mas exigiam padronização rigorosa de formatos e identificadores de celular.

## **4. Limpeza e Padronização**

### **4.1. Processos Realizados**

Padronização de nomes de colunas: substituição de espaços e acentuação.

Conversão de campos monetários: valor\_cupom, repasse\_picmoney → float.

Normalização de telefones: remoção de () - e espaços com df['celular'].str.replace(r'\D', '').

Datas e horários: convertidos com pd.to\_datetime() e formato %d/%m/%Y %H:%M:%S.

Latitude/Longitude: substituição de vírgula por ponto e exclusão de duplicatas.

Remoção de duplicados e valores impossíveis (ex: idade negativa).

### **4.2. Impacto**

A limpeza reduziu 2% das linhas totais por inconsistência e garantiu um dataset 100% integrável.

### **Insight de Negócio**

A uniformização garante integridade nas futuras integrações e dashboards, reduzindo retrabalho interno e melhorando a confiabilidade das análises.

## **5. Integração das Bases**

### **5.1. Estratégia de Junção**

Integração realizada com base na chave “celular”, conforme:

```
merged = df_cadastro.merge(df_transacoes, on='celular', how='left')
merged = merged.merge(df_pedestres, on='celular', how='left')
```

## 5.2. Resultado

Gerou-se um dataset unificado (merged\_test) com mais de 100 mil registros, consolidando:

- Dados pessoais (idade, gênero, local)
- Dados de transação (valor, categoria, cupom)
- Dados geográficos (presença física e app)
- Dados simulados (validação de hipóteses)


### Insight de Negócio

A integração permite compreender o comportamento digital e físico do cliente, possibilitando ações como:


Envio de cupons em tempo real com base em localização.


Segmentação por frequência e gasto médio.

### Distribuição de Usuários por Sexo



### Top 10 Categorias Mais Frequentadas pelos Usuários





## 6. Criação de Variáveis Derivadas

### 6.1. Novas Métricas Criadas

Variável	Descrição	Fórmula/Processo
frequencia_cupons	Quantidade de cupons por usuário	df.groupby('celular')['cupom'].count()
ticket_medio	Valor médio gasto por compra	valor_total / qtd_transacoes
repasse_medio	Percentual médio de repasse	repasse_picmoney / valor_cupom
status_usuario	Classificação de uso	Ativo/Inativo

### 6.2. Observações Analíticas


Top 10% dos usuários concentram ~45% da receita total.


Usuários com maior repasse médio utilizam mais cupons (maior retenção).

Ticket médio mais alto entre 30–45 anos.

### Insight de Negócio

Existe forte correlação entre incentivo financeiro e fidelização. Usuários com recompensas maiores tendem a permanecer mais engajados no ecossistema.





## 7. Análise Exploratória e Preparação Final

### 7.1. Visualizações e Distribuições

Foram utilizadas ferramentas como matplotlib e seaborn para identificar padrões:

Distribuição Etária: maior concentração entre 25 e 40 anos.

Categorias Mais Populares: Farmácias, Restaurantes e Lojas de Conveniência.

Geolocalização: Alta densidade de pedestres na Av. Paulista entre 9h e 18h.

Adoção do App: 62% dos pedestres possuem o app, indicando penetração significativa.


### 7.2. Preparação Final


A base final foi exportada em formato .csv limpo, pronta para uso em modelagem preditiva ou dashboards analíticos.

## Insight de Negócio

A análise mostra um público adulto jovem urbano, com forte engajamento em cashback e fidelização.



A região da Paulista representa oportunidade de expansão em campanhas de presença local.





Top 10 Categorias por Receita Gerada





## 8. Conclusão Geral

A análise consolidou um pipeline completo de preparação e integração de dados da PicMoney, resultando em:

- **Base unificada e padronizada** entre cadastro, transação e mobilidade.
- Identificação de **segmentos de alto valor e retenção**.

- **Validação da coerência entre bases** e definição de métricas estratégicas.